深入理解大数据-大数据处理与编程实践

大数据开源项目的开发工具与流程简介

南京大学计算机科学与技术系

主辦人: 實宜华 顾蒙

鸣谢:本课程得到Google公司(北京)

中国大学合作部精品课程计划资助

大数据开源项目的开发工具与流程简介

- 1. 开发环境工具IntelliJ IDEA简介
- 2. 代码库版本控制工具Git简介
- 3. 项目组织管理工具Maven简介
- 4. 项目的Code Style
- 5. 实验1: 基本开发工具的安装使用以及开发流程熟悉
- 6. 实验指南

1.开发环境工具IntelliJ IDEA简介

 IntelliJ IDEA是一个相当智能化的Java、Scala开发IDE 环境

IntelliJ IDEA is focused on raising your productivity by providing instant and clever code completion, on-the-fly code analysis, easy project navigation and reliable refactorings.

For Eclipse user:

IntelliJ IDEA没有类似Eclipse的workspace,最顶级的是Project,次级别是Module,一个Project可以有多个Module,每个project需要打开一个窗口(类似Visual Studio)

●官网

https://www.jetbrains.com/idea/

• 参考教程

http://wiki.jikexueyuan.com/project/intellij-idea-tutorial/ (中文)
https://www.jetbrains.com/idea/help/meet-intellij-idea.html

开发环境工具IntelliJ IDEA简介

Intellij IDEA 基本界面

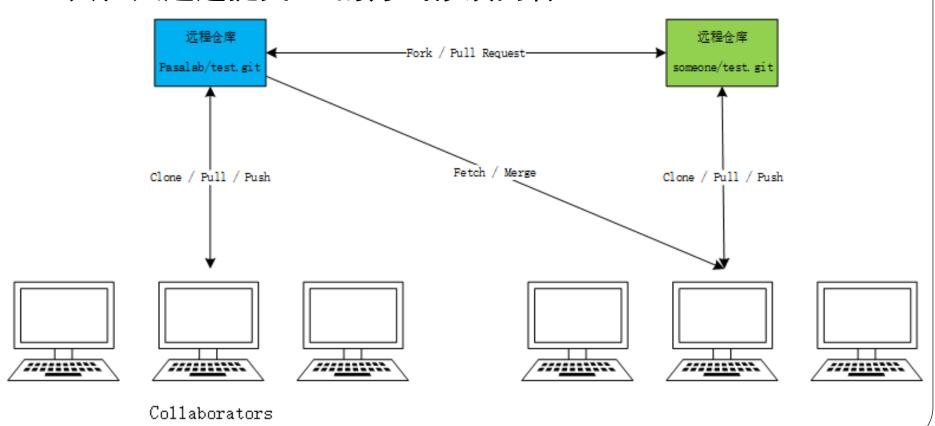
```
🛂 alluxio-parent - [D:\alluxio] - [alluxio-core-client] - ...\core\client\src\main\java\alluxio\client\file\FileOutStream.java - IntelliJ IDEA 2016.2.1
File Edit View Navigate Code Analyze Refactor Build Run Tools VCS Window Help
                                                                                                                                            ୍ୟାମ୍ମ ▼ ▶ 💥 🖄 🔳 VCS VCS 👺 5
📑 alluxio 🕽 😭 core 🕽 😭 client 🕽 src 🕽 🖿 main 🕽 🚍 java 🕽 🗖 alluxio 🕽 🗖 client 🕽 🗖 file 🕽 🕲 FileOutStream
                               🕀 🖶 | 🕸 🖟 🖟 🕝 HdfsUnderFileSystem.java × 🐧 FileSystem.java × 🕝 FsPermission.java × 🧸 FileOutStream.java >
                                                                                                                                C BaseFileSystem.java × C CreateFileOptions.java ×
▼ alluxio [alluxio-parent] D:\alluxio
                                                        FileOutStream FileOutStream()
  ▶ 🗖 .idea
  assembly [alluxio-assemblies]
  ▶ 🗀 bin
                                                        package alluxio.client.file;
  ▶ 🗀 build
  conf
  ► core [alluxio-core]
  ▶ 🗖 deploy
  ▶ □ docs
  examples [alluxio-examples]
  ► integration [alluxio-integration]
                                                          * Alluxio space in the local machine or remote machines. If the {@link UnderStorageType} is
                                                          * {@link UnderStorageType#SYNC PERSIST}, another stream will write the data to the under storage
  keyvalue [alluxio-keyvalue]
  ▶ 🗖 libexec
  ▶ 🗖 logs
                                                        @PublicApi
  minicluster [alluxio-minicluster]
                                                         @NotThreadSafe
  ► shell [alluxio-shell]
                                                        public class FileOutStream extends AbstractOutStream {
                                                           private static final Logger LOG = LoggerFactory.getLogger(Constants.LOGGER TYPE);
  ► tests [alluxio-tests]
  underfs [alluxio-underfs]
                                                           private final long mBlockSize;
     gitignore.
                                                           protected final AlluxioStorageType mAlluxioStorageType;
     alluxio-parent.iml
                                                           private final UnderStorageType mUnderStorageType;
     LICENSE
                                                           private final FileSystemContext mContext;
     NOTICE
                                                           private final OutputStream mUnderStorageOutputStream;
                                                           private final long mNonce;
     README.md
   External Libraries
                                                           private final FileSystemWorkerClient mFileSystemWorkerClient;
                                                           private final Long mUfsFileId;
                                                                                                                                               93:18 CRLF$ UTF-8$ Git: branch-1.2$ % #
Platform and Plugin Updates: IntelliJ IDEA is ready to update. (a minute ago)
```

Git简介

- Git是一个分布式版本控制工具,适用于管理
 - 大型开源软件源码
 - 个人软件源码
 - 私人文档
 - ...
- 在不同粒度上进行版本控制,能够得到任意一个版本的内容
 - 仓库(repository)
 - 分支(branch)
 - 每一次的改动(commit)

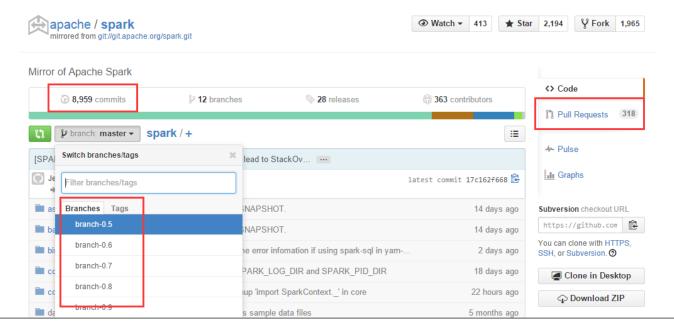
Git项目分布框架

- 项目存储于远程版本库中
- Collaborators拥有直接修改远程仓库内容的权限
- 其他人通过提交PR的方式修改内容



Git项目版本框架

- 一个项目为一个Repository
- 一个Repository可包含多个分支(Branch)
- 通常不同版本对应不同分支
- 一个分支由若干Commit构成
- 一个Commit表示一次内容修改
- 一个Commit可以包含对多个文件内容的修改
- 一个PR可以包含多个Commit



安装Git

- 这里的安装主要是指Git的客户端
 - For Windows
 - Git for Windows (适合shell 命令使用)
 - GitHub Desktop(良好界面的桌面应用,仅适合Github)
 - For Linux
 - apt-get install git
 - yum install git
- 安装完后 git --version 检查版本

使用Git

- 本地从零开始
 - 对于现有项目
 - [可选]在网页上fork repository
 - git clone https://github.com/github/gitignore
 - 对于新建项目
 - 在网页上new repository后
 - git clone https://github.com/someone/test.git
 - 本地 git init
 - git remote add origin https://github.com/someone/test.git

使用Git

• 从命令行创建新仓库

```
touch README.md #创建README.md文件
git init #初始化git项目格式,生成.git文件夹
git add README.md #将README.md添加到缓存
git commit -m "first commit" #记录缓存内容的快照,并提交注释 "first commit"
git remote add origin http://website/repo.git #为项目添加一个别名为origin的远端仓库
git push -u origin master #推送你的master分支与数据到名为origin的远端仓库
```

• 从命令行推送已有仓库

```
git remote add origin http://website/repo.git #为项目添加一个别名为origin的远端仓库 git push -u origin master #推送你的master分支与数据到名为origin的远端仓库
```

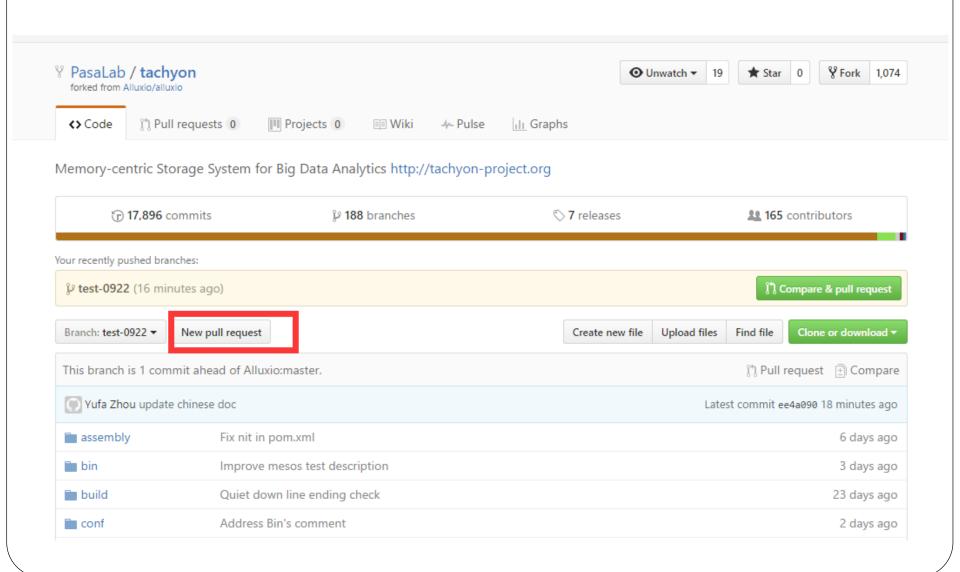
使用Git

- 对项目进行修改
 - 作为Collaborator
 - (在本地对内容进行了更改)
 - git commit #生成一次commit,包含修改的内容
 - git push #将本地的修改提交至远程仓库
 - 非Collaborator
 - 在网页上create a pull request
 - 等待PR被merge

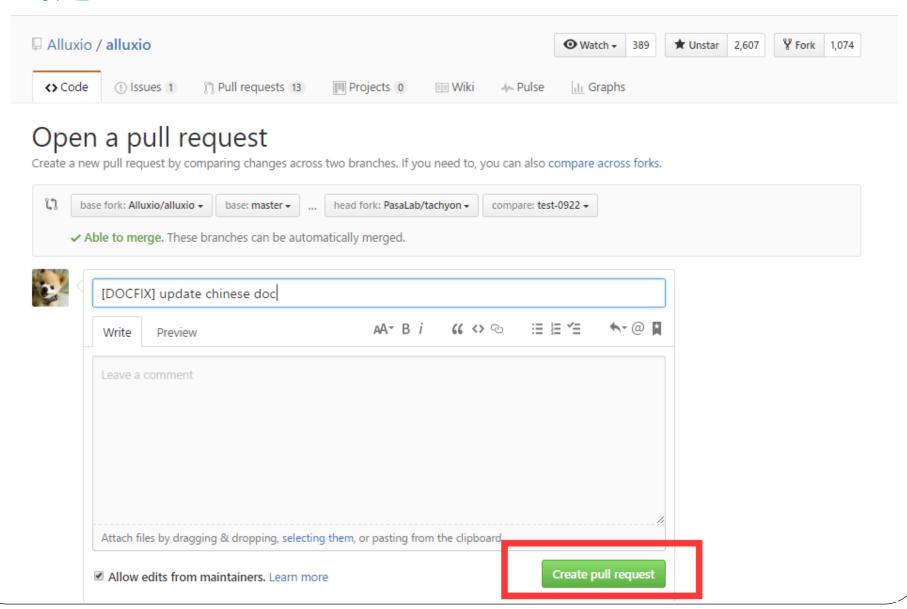
使用Git

- 同步最新的项目至本地
 - 作为Collaborator
 - git pull
 - 非Collaborator
 - git fetch upstream
 - git merge upstream/somebranch
 - 至此,本地代码已更新
 - git push origin somebranch:somebranch
 - 至此,远程仓库代码已更新

创建PR



创建PR



使用Git

- 分支管理
 - 查看本地分支 git branch
 - 查看远程分支 git branch -r
 - 创建本地分支 git branch [name]
 - 切换分支 git checkout [name]
 - 删除分支 git branch -d [name]
 - 创建远程分支 git push origin [name]
 - 删除远程分支 git push origin :[name]

使用Git

- 对开源项目作贡献的一般流程
 - fork a repository
 - git clone https://github.com/PasaLab/tachyon.git
 - git checkout master
 - git remote add upstream https://github.com/Alluxio/alluxio.git
 - git fetch upstream
 - git merge upstream/master
 - git checkout -b new-branch
 - (本地修改内容)
 - git add <the files you modified>
 - git commit –m "modify something"
 - git push origin new-branch:new-branch
 - create a pull request

其他

- Git功能远比上述要强大
- Git参考手册 http://gitref.org/zh/index.html
- GitHub https://github.com/
- https://help.github.com/articles/create-a-repo/
- https://help.github.com/articles/fork-a-repo/
- https://help.github.com/articles/using-pull-requests/
- 不错的Blog http://blog.csdn.net/ithomer/article/details/7529022

Maven简介

- Maven 是一个项目管理和构建自动化工具
 - 构建项目框架
 - 管理项目结构
 - 自动解析依赖
 - 灵活插拔插件
 - 本地Maven库
- •目前, Hadoop、Spark、Alluxio均由Maven构建

Maven核心概念

- POM(Project Object Model)文件
 - 以xml形式对项目进行描述
 - 基本信息、依赖信息、插件信息等
- Maven依赖项
 - 项目之间的依赖关系
 - 自动解析并从库中获取必要的包
- Maven库
 - 本地库&远程库,包含所有项目所需的依赖包
 - 优先从本地库中寻找
 - http://mvnrepository.com/ (default Maven 2 repository)
 - https://maven-repository.com/ (can search other repositories)

Maven安装

- Linux、Windows均可,需要先安装Java
- 下载apache-maven-x.y.z.bin.zip/tar.gz
- http://maven.apache.org/download.cgi
- 解压
- 配置环境变量
 - M2_HOME=/path/to/maven
 - M2=\$M2_HOME/bin
 - add \$M2 to \$PATH
- mvn --version 检查版本

Maven基本命令

- mvn archetype:generate -DgroupId=[xxx] DartifactId=[yyy] -Dpackage=[zzz] -Dversion=[0.1 SNAPSHOT] 新建Maven项目框架
- mvn compile 编译项目源码
- mvn test 运行测试
- mvn package 将项目打包
- mvn install 将项目安装到本地库
- mvn clean 清除已生成的项
- 编译举例:
- 打包Spark,依赖Hadoop版本为2.6,且支持native library,略过测试
- mvn package –Phadoop-2.6 –Pnetlib-lgpl –DskipTests

Maven基本命令

- 编译举例:
- 打包Spark, 依赖Hadoop版本为2.6, 且支持native library,
 略过测试
- mvn package –Phadoop-2.6 –Pnetlib-lgpl –DskipTests

```
file>
                                                                   <id>netlib-lgpl</id>
file>
                                                                   <dependencies>
  <id>hadoop-2.6</id>
                                                                     <dependency>
  properties>
                                                                        <groupId>com.github.fommil.netlib
     <hadoop.version>2.6.0</hadoop.version>
                                                                        <artifactId>all</artifactId>
     <jets3t.version>0.9.3</jets3t.version>
                                                                        <version>${netlib.java.version}</version>
     <zookeeper.version>3.4.6</zookeeper.version</pre>
                                                                        <type>pom</type>
     <curator.version>2.6.0/curator.version>
                                                                     </dependency>

<
                                                                   </dependencies>
</profile>
                                                                </profile>
          pom.xml的profile
                                                                            mllib/pom.xml的profile
```

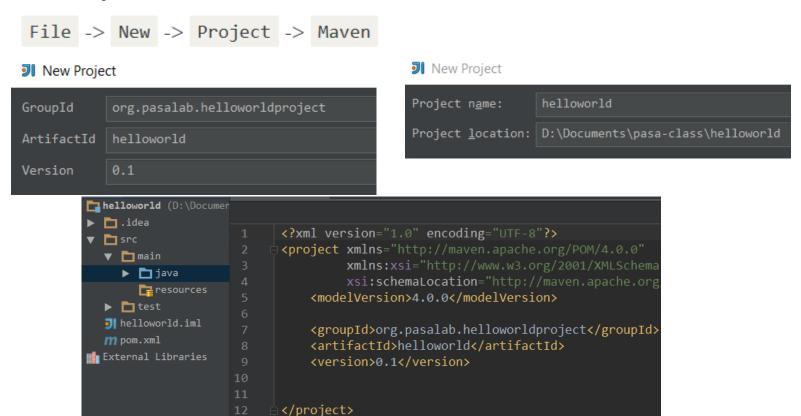
skipTests: 插件maven-surefire-plugin的配置选项

Maven插件命令

- eclipse插件,生成eclipse能够识别的项目 mvn eclipse:eclipse
- javadoc插件, 生成Java API Doc mvn javadoc:javadoc
- checkstyle插件,对源码进行格式检查 mvn checkstyle:checkstyle
- <u>scala-maven-plugin</u> Java-Scala代码混合编译
- http://maven.apache.org/plugins/

Maven - Hello World

- 命令行生成Maven项目
 mvn archetype:generate -DgroupId=org.pasalab.helloworldproject -DartifactId=helloworld -Dpackage=org.pasalab.helloworld -Dversion=0.1
- 用Intellij IDEA生成Maven项目



Maven – Hello World

```
🚹 Project 🕨
                 helloworld (D:\Documents\pasa-class 1
                                   package org.pasalab.helloworld;
 🛅 .idea
  🔻 🛅 main
                                   public class App {
    ▼ 🛅 java
                                       public static void main(String[] args) {
      ▼ in org.pasalab.helloworld 6
                                          System.out.println("hello world");
           C 🚡 App
      resources
  test
 target
  helloworld.iml
  m pom.xml
 External Libraries
```

- mvn package
- java -cp target/helloworld-0.1 org.pasalab.helloworld.App

```
D:\Documents\pasa-class\helloworld
  java -cp .\target\helloworld-0.1.jar org.pasalab.helloworld.App
hello world
```

进一步学习Maven

- 详细的官方文档
 - http://maven.apache.org/index.html
- 不错的Maven入门教程
 - http://www.oracle.com/technetwork/cn/community/java/apache-maven-getting-started-1-406235-
 zhs. html
- 具体的POM文件分析
 - Hadoop Spark Alluxio

4.项目的Code Style

Code Style

- 作用
 - 整个工程项目代码风格统一, 便于管理
 - 方便code review
 - 一定程度避免某些低级错误
 - 代码风格本身带有一定语义
- 规则约定
 - Doc上约定
 - Maven脚本定义规则
- 检查
 - 人工检查
 - Maven自动检查

项目的Code Style

Alluxio项目Code Style

- 2空格缩进
- 每行不超过100字符
- import语句根据前缀分组
- 类成员变量以m为前缀
- 静态类变量以s为前缀
- 具体参考

http://www.alluxio.org/docs/master/en/Contrib
uting-to-Alluxio.html

Alluxio项目Code Style



```
@NotThreadSafe // TODO(jiri): make thread-safe (c.f. ALLUXIO-1624)
public final class TieredBlockStore implements BlockStore {
  private static final Logger LOG = LoggerFactory.getLogger(Constants.LOGGER TYPE);
  // TODO(bin): Change maxRetry to be configurable.
  private static final int MAX RETRIES = 3;
  private final BlockMetadataManager mMetaManager;
  private final BlockLockManager mLockManager;
  private final Allocator mAllocator;
  private final Evictor mEvictor;
  private final List<BlockStoreEventListener> mBlockStoreEventListeners = new ArrayList<>();
  private final Set<Long> mPinnedInodes = new HashSet<>();
  /** Lock to guard metadata operations. */
  private final ReentrantReadWriteLock mMetadataLock = new ReentrantReadWriteLock();
  private final Lock mMetadataReadLock = mMetadataLock.readLock();
  private final Lock mMetadataWriteLock = mMetadataLock.writeLock();
  /** Association between storage tier aliases and ordinals. */
  private final StorageTierAssoc mStorageTierAssoc;
  public TieredBlockStore() {
    mMetaManager = BlockMetadataManager.createBlockMetadataManager();
    mLockManager = new BlockLockManager();
    BlockMetadataManagerView initManagerView = new BlockMetadataManagerView(mMetaManager,
        Collections.<Long>emptySet(), Collections.<Long>emptySet());
    mAllocator = Allocator.Factory.create(initManagerView);
    if (mAllocator instanceof BlockStoreEventListener) {
      registerBlockStoreEventListener((BlockStoreEventListener) mAllocator);
```

5.实验1:基本开发工具的安装使用以及参与 大数据存储系统Alluxio的开发

实验内容与要求

- 1. 在本机上安装Maven、Git;
- 2. 创建自己的Github帐号;
- 3. 将Alluxio/alluxio(https://github.com/Alluxio/alluxio)fork到自己的Github仓库,clone到本地,建立新的分支完成给定任务(任务待分配),并在本地使用maven进行编译测试(需在linux环境下);
- 4. 编译测试成功后提交commit, 并push到自己Github帐号远程仓库相应分支,最后创建并提交pull request至Alluxio/alluxio (https://github.com/Alluxio/alluxio) (参考
- http://www.alluxio.org/docs/master/cn/Contributing-to-
- Alluxio.html);
- 5. 及时处理PR页面中他人提出的修改意见,本地修改后push到自己 Github帐号远程仓库即可(不需要重新创建PR),并等待最终 merge。

实验1:基本开发工具的安装使用以及参与 大数据存储系统Alluxio的开发

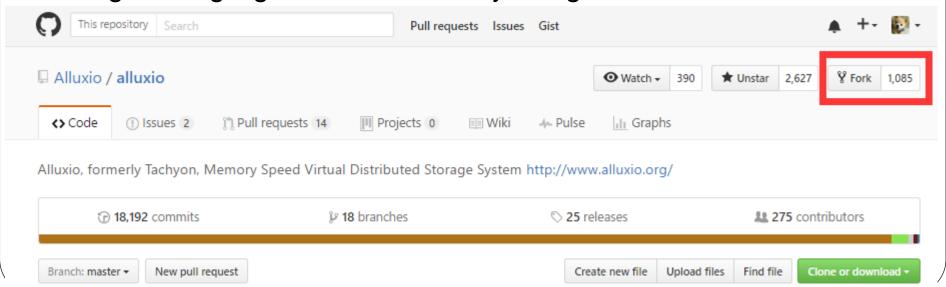
注意事项

- 每人只能完成自己的任务,若完成他人的任务则不 计分;
- 确保修改后在本地进行编译测试并通过再提交;
- 注意pull request标题及描述格式;
- 时常关注pull request页面,并及时处理相应评论
- 在本学期课程后面的作业项目中,尽量使用Maven 搭建管理整个工程,会有相应加分

6.实验指南

相关软件安装以及fork Alluxio仓库

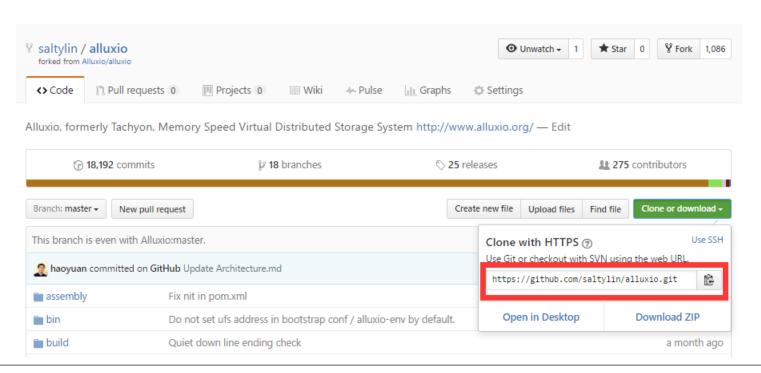
- 在本机安装Maven、Git;
- 创建自己的Github账号(假设账号名为someone);
- 将Alluxio项目(https://github.com/Alluxio/alluxio)fork到自 己Github远程仓库
- 本地配置git, 命令行下运行以下命令
 - \$git config --global user.name "your_name"
 - \$git config --global user.email "your_github_email"





Clone代码到本地、添加远程源并fetch最新代码

- git clone https://github.com/someone/alluxio.git
- 进入项目根目录 cd alluxio
- git checkout master
- git remote add upstream https://github.com/Alluxio/alluxio.git
- git fetch upstream
- git merge upstream/master

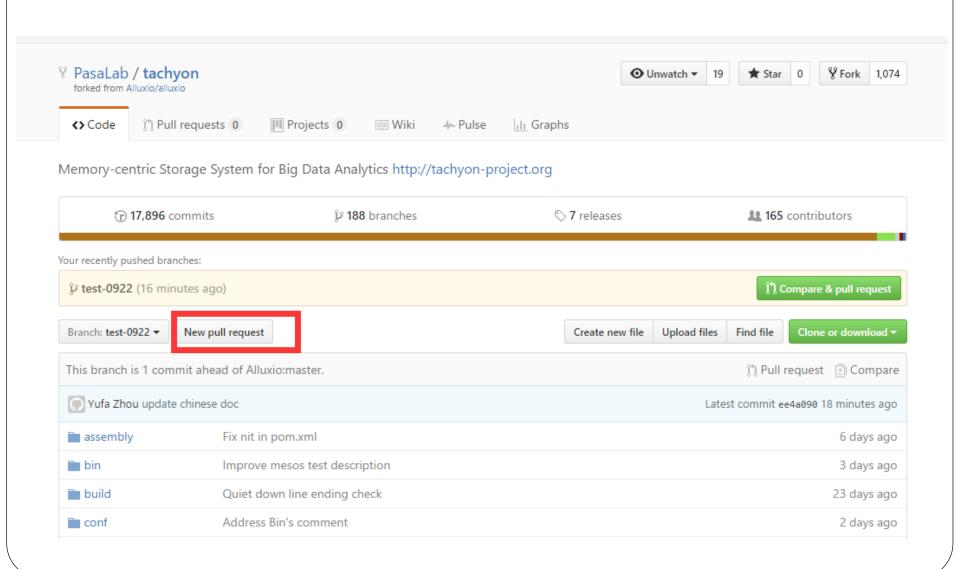


新建分支并完成指定任务

- git checkout -b <my-branch-name>
- 修改相应文件
- 编译测试(在linux环境) mvn clean install
- 查看当前Git修改状态 git status
- git add <修改的文件> 或者 git add .
- git commit –m "the description for the commit (简单描述你的修改)"
- git push origin <my-branch-name>:<my-branch-name>

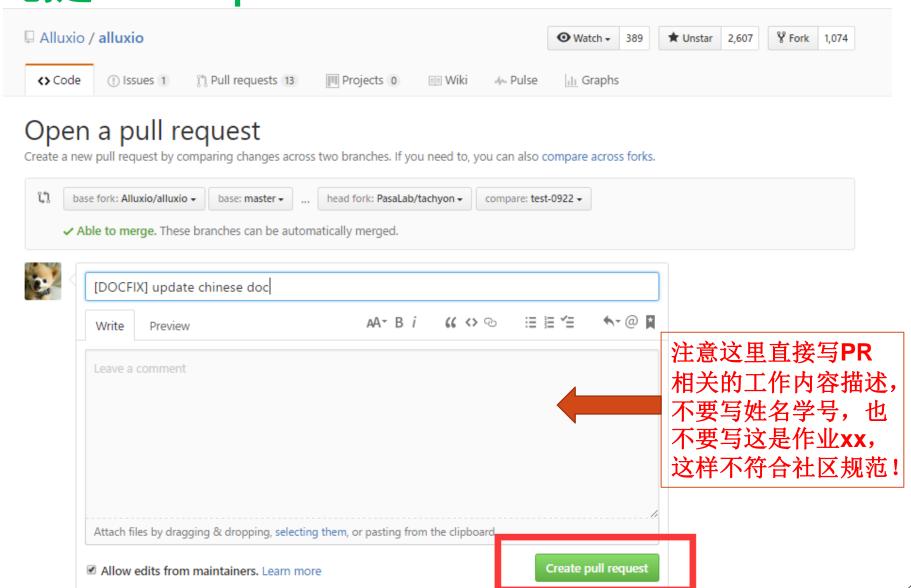


创建Pull Request





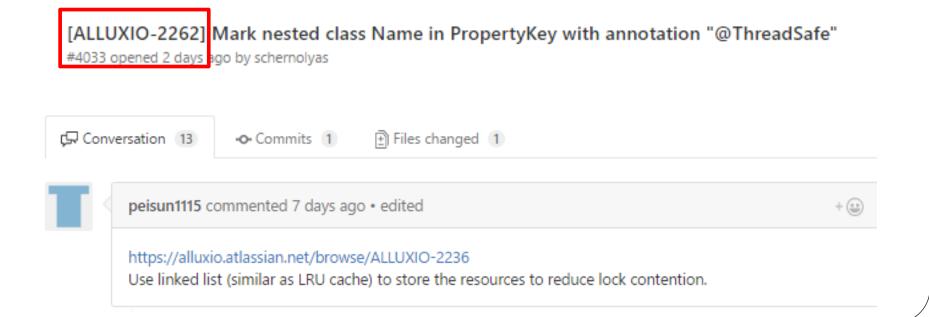
创建Pull Request





创建Pull Request

- 创建PR时,PR的标题通常以[ALLUXIO-xxxx]为前缀(如图),如果是针对docs进行的修改则为[DOCFIX]前缀
- 若该任务为某一jira任务,则在description框中的第一行添加 该jira的链接





Contribution license agreement

 创建PR后,会有个 alluxio-bot 提示需要`sign a contribution license agreement`,这个作用是确保我们写的代码能够被 开源社区接受和使用,按照提示填写信息(需填写完整), 之后会收到相关邮件,按提示进行操作即可



Alluxio-bot commented 13 hours ago

Hi thanks for your contribution!

In order for us to evaluate and accept your PR, we ask that you sign a contribution license agreement. It's all electronic and will take just minutes.

处理PR页面中别人提出的评论及修改意见

- 切换到该PR对应的分支 git checkout <my-branch-name>
- 进行相应修改
- 编译测试 mvn clean install
- 查看当前Git修改状态 git status
- git add <修改的文件> 或者 git add .
- git commit –m "the description for the commit"
- git push origin <my-branch-name>:<my-branch-name>
- 注意, push到自己Github远程仓库就行了, 不需要再次创建 PR, 相应的PR会检测到这次更改

实验指南

Alluxio开源项目微信公众号



Thanks!